

Phần 1 — Lý thuyết

PHẦN 1 — LÝ THUYẾT: TỪ INTELLIGENCE ĐẾN INTELLIGENT SYSTEM

Môn học: Intelligent System Development — Assignment 01 From Data Representation to a First Intelligent System

“Understand the system, represent the information, learn from data, and turn the model into an application.”

1. Intelligence là gì? — Quan điểm chức năng (functional view)

Không có một định nghĩa kỹ thuật duy nhất được chấp nhận rộng rãi cho *intelligence*. Môn học này tiếp cận theo **quan điểm chức năng**: một hệ thống được coi là “có trí tuệ” khi nó *thực hiện được* các năng lực sau (Slide 01, trang 6):

Năng lực	Câu hỏi cốt lõi	Cơ chế điển hình
Perception (tri giác)	Hệ thống nhận thông tin gì từ môi trường?	Sensor, dữ liệu, API
Representation (biểu diễn)	Thông tin được biểu diễn bên trong như thế nào?	Feature vector, tensor, graph, embedding
Learning (học)	Hệ thống học từ đâu?	Machine learning, deep learning
Reasoning (suy luận)	Hệ thống suy luận ra sao dưới bất định?	Logic, search, xác suất
Decision (quyết định)	Hệ thống chọn hành động nào?	Ngưỡng quyết định, policy, tối ưu hóa
Action (hành động)	Hệ thống tác động lên môi trường ra sao?	Dự đoán, cảnh báo, giao diện người dùng
Adaptation (thích nghi)	Hệ thống cải thiện từ phản hồi không?	Feedback, continual learning

Điểm mấu chốt: Intelligence không phải là một thuật toán duy nhất. Trí tuệ *nổi lên* (emerges) từ sự **phối hợp các năng lực** (Slide 01, trang 7).

1.1 Khái niệm “intelligence” trong Assignment 01

Assignment 01 cố tình xử lý intelligence theo nghĩa **hẹp và có thể vận hành được** (limited and operational sense). Hệ thống thể hiện một *hình thức* trí tuệ khi nó có thể:

- Nhận thông tin** (receive information);
- Biểu diễn thông tin liên quan một cách tính toán** (represent relevant information computationally);
- Học một quan hệ từ các ví dụ** (learn a relationship from examples);
- Tạo ra dự đoán cho một trường hợp mới** (produce a prediction for a new case);
- Hỗ trợ một quyết định hoặc ứng dụng** (support a decision or application).

Từ đó, working notion of intelligence cho Assignment 01 là:

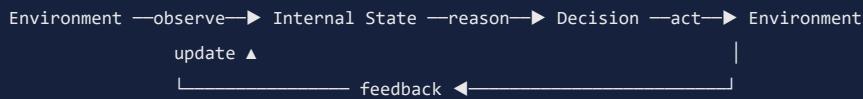
Learning from examples + Generalization + Prediction

Đây không phải định nghĩa hoàn chỉnh về trí tuệ. Các assignment sau sẽ mở rộng qua deep learning (A3), kiến thức + đồ thị (A4), embedding/RAG/tương tác/triển khai (A5).

2. Intelligent System là gì? — Abstraction kỹ thuật

Slide 01 (trang 8) đưa ra một abstraction kỹ thuật hữu ích:

IntelSys = (Environment, State, Representation, Knowledge, Learning, Decision, Action)



Phân biệt quan trọng nhất: *external state* (thế giới thực) $\neq$ *internal/cognitive state* (biểu diễn bên trong hệ thống).

Hệ thống **không sở hữu trực tiếp** toàn bộ thế giới thực. Nó vận hành thông qua **quan sát (observations)** và **biểu diễn (representations)**.

2.1 Sự khác nhau: Model $\neq$ Application $\neq$ Intelligent System

Khái niệm	Bản chất	Thành phần
Model	Hàm học được $f_{\theta}(x)$	Learned mapping
Application	Model làm ra usable	model + interface + data processing
Intelligent System	Application vận hành trong môi trường	application + state + interaction + feedback

Từ đó rút ra nguyên lý xuyên suốt môn học:

ML model $\neq$ complete intelligent system

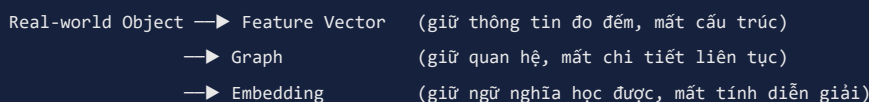
Assignment 01 hiện thực hóa nguyên lý này bằng cách **bắt buộc** biến model thành application (mục 17 trong đề): model một mình chưa phải là hệ thống hoàn chỉnh.

3. Representation — Ý tưởng trung tâm của toàn bộ môn học

3.1 Nguyên lý nền tảng (Foundation / Key principle)

Model không nhận “thế giới thực”. Model nhận một biểu diễn (representation) của thông tin được lựa chọn.
Do đó: Representation quyết định thông tin nào có sẵn cho học.

Slide 01 (trang 24) nhấn mạnh: **Representation không phải lựa chọn trung tính** (Representation is not a neutral choice). Cùng một đối tượng thực có thể được biểu diễn nhiều cách:



Mỗi representation **giữ lại một phần thông tin và loại bỏ/su biến đổi phần khác**:

Representation $\Rightarrow$ available information $\Rightarrow$ possible learning

3.2 Feature vector — Representation của dữ liệu có cấu trúc

Với dữ liệu có cấu trúc (structured data), một quan sát được biểu diễn bằng **feature vector**:

$$x_i = [x_{i1}, x_{i2}, \dots, x_{id}] \in \mathbb{R}^d$$

Một dataset có giám sát (supervised dataset):

$$D = \{(x_i, y_i)\}_{i=1}^N$$

trong đó: - x_i : input representation (biểu diễn đầu vào); - d : số đặc trưng (features); - y_i : target (giá trị mục tiêu); - N : số quan sát (observations).

Ma trận đặc trưng hoàn chỉnh:

$$X \in \mathbb{R}^{N \times d}$$

3.3 Ba tầng representation phải phân biệt (mục 8 đề bài)

Raw feature $\neq$ Encoded feature $\neq$ Model input

Ví dụ trong hệ Chẩn đoán bệnh tim: - **Raw feature**: cp (loại đau ngực) nhận giá trị 1–4 — biến phân loại theo thang đo định danh; - **Encoded feature**: sau one-hot encoding thành 4 cột nhị phân cp_1..cp_4 ; - **Model input**: sau chuẩn hóa (standardization) các đặc trưng số — giá trị $z = \frac{x-\mu}{\sigma}$.

Sự thay đổi representation ở tầng preprocessing **thay đổi hẳn** không gian mà thuật toán học “nhìn thấy”.

3.4 Tiến hóa của representation trong lịch sử AI (Slide 01, trang 22–23)

Symbols $\rightarrow$ Features $\rightarrow$ Vectors $\rightarrow$ Tensors $\rightarrow$ Graphs $\rightarrow$ Embeddings $\rightarrow$ Multimodal

Cấu trúc thông tin	Representation tự nhiên	Model điển hình	Giai đoạn môn học
Bản ghi có cấu trúc	Feature vector $x \in \mathbb{R}^d$	LR, KNN, SVM, Trees	A1–A2
Hình ảnh	Tensor	CNN, ViT	Deep Learning
Chuỗi (sequence)	Vector sequence	RNN, LSTM, Transformer	Deep Learning
Quan hệ	Nodes + edges	GNN	Knowledge/Graph
Tri thức	Entities + relations	KG reasoning	Knowledge Graph
Văn bản	Embeddings	Similarity search	RAG
Đa phương thức	Nhiều representation	Multimodal AI	Final Project

Lịch sử của AI cũng là lịch sử của representations — đây là câu chủ đạo nối Assignment 01 với toàn bộ lộ trình môn học.

4. Traditional Machine Learning — Vị trí trong lịch sử AI

4.1 Timeline khái niệm (Slide 01, trang 10–12)

Giai đoạn	Paradigm	Ý tưởng chính	Representation điển hình
1950s–60s	Symbolic AI	Logic, search, problem solving	Symbols / rules
1970s–80s	Expert Systems	Mã hóa tri thức chuyên gia	Rules / knowledge base
1980s–2000s	Statistical ML	Học pattern từ ví dụ	Feature vectors
2000s–2010s	Deep Learning	Học representation phân tầng	Tensors
2010s	Large-scale DL	Data + compute + learned repr.	High-dim tensors
Late 2010s–2020s	Transformers	Attention, sequence modeling	Embeddings / tokens
2020s	Foundation/Gen AI	Reusable learned capabilities	Multimodal embeddings
Hiện tại	Interactive/Agentic	Perceive, reason, use tools, act	State + memory + tools

4.2 Era 3: Statistical ML — sự dịch chuyển cốt lõi

Program the rules → Learn patterns from examples

Symbolic AI

Statistical ML

Thay vì con người viết luật IF fever AND cough THEN possible_infection, hệ thống **tự suy ra** quan hệ input → output từ dữ liệu:

$$\hat{y} = f_{\theta}(x)$$

Các phương pháp điển hình: **Logistic Regression, k-Nearest Neighbors, Support Vector Machines, Decision Trees, Random Forests** — đúng 5 nhóm model Assignment 01 yêu cầu.

Hệ quả quan trọng: khi học từ dữ liệu thay vì viết luật, **representation trở thành bài toán kỹ thuật trung tâm** (Representation becomes a central engineering problem).

4.3 Traditional ML vs Deep Learning — phân biệt bắt buộc phải nắm

Tiêu chí	Traditional ML	Deep Learning
Representation	Human-designed features	Learned representations
Pipeline	Data → Human features → ML Model → Prediction	Data → Learned repr. → Prediction
Dạng dữ liệu	Vector cố định chiều	Vectors, tensors, sequences
Model học gì	Quan hệ dự đoán	Representation + quan hệ dự đoán
Hiệu quả	Dữ liệu có cấu trúc	Dữ liệu phi cấu trúc phức tạp
Kích thước model	Nhỏ	Lớn
Sở hữu trong môn học	Assignment 01: feature engineering	A3+: representation learning

Traditional ML : human-designed feature representation + learned prediction model

con người thiết kế

máy học

Deep Learning : learned representation + learned prediction model

máy học

máy học

4.4 Vì sao Traditional ML phù hợp Assignment 01?

1. **Formulation toán minh bạch** — sinh viên kiểm chứng được từng thành phần;
2. **Representation kiểm tra trực tiếp được** — feature vector con người đọc hiểu;
3. **Nhiều thuật toán cổ điển so sánh được** trong cùng một protocol;
4. **Experiment kiểm soát và giải thích được**;
5. **Deployment tạo ra góc nhìn hệ thống** (system perspective).

We start simple so that the development principles are visible. (Slide 01, trang 33)

5. Formulating the Learning Problem — Toán học của việc học

5.1 Bài toán học có giám sát

Cho dataset:

$$D = \{(x_i, y_i)\}_{i=1}^N$$

hệ thống tìm hàm dự đoán:

$$\hat{y} = f_{\theta}(x)$$

Quá trình học là **tìm tham số tối ưu** theo tiêu chí tối thiểu hóa mất mát trung bình:

$$\theta^* = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \ell(f_{\theta}(x_i), y_i)$$

Giải thích từng ký hiệu (đề bài yêu cầu sinh viên giải thích mọi ký hiệu):

Ký hiệu	Ý nghĩa	Ví dụ trong hệ bệnh tim
$x_i \in \mathbb{R}^d$	Input representation của quan sát thứ i	Vector 13 chỉ số tim mạch
y_i	Target (label) của quan sát thứ i	0 = khỏe, 1 = mắc bệnh tim
f_{θ}	Họ hàm dự đoán tham số hóa bởi θ	Logistic Regression, RF, ...
θ	Tham số model (weights, biases, cấu trúc cây)	w, b của LR
$\hat{y}$	Dự đoán cho input mới	Xác suất/bán quyết bệnh tim
$\ell(\cdot, \cdot)$	Loss function đo sai khác dự đoán–thực tế	Cross-entropy / Gini impurity
θ^*	Tham số tối ưu tìm được	Kết quả <code>model.fit()</code>

5.2 Classification vs Regression

Classification — dự đoán lớp:

$$x \rightarrow \hat{y} \in \{1, \dots, K\}$$

Ví dụ: disease/healthy, spam/not spam. *Hệ Chẩn đoán bệnh tim của em thuộc loại này (nhị phân, $K = 2$).*

Regression — dự đoán lượng số:

$$x \rightarrow \hat{y} \in \mathbb{R}$$

Ví dụ: house price, temperature. *Hệ Dự đoán giá nhà của em thuộc loại này.*

5.3 Training ≠ Testing — vì sao phải tách

$$D = D_{train} \cup D_{test}$$

- **Training set:** nguồn để thuật toán học quan hệ (tìm θ^*);
- **Test set:** mô phỏng dữ liệu chưa từng thấy để **ước lượng khả năng khái quát (generalization)**.

Vì sao test set không được dùng làm nguồn huấn luyện? Nếu model “nhìn thấy” test set trong quá trình phát triển (chọn model, chỉnh hyperparameter dựa trên test score), kết quả đánh giá sẽ bị **lạm phát** — model thuộc nhớ dữ liệu (overfitting/memorization) thay vì khái quát. Đề bài liệt kê “*Using the test set repeatedly during model development*” vào danh mục điều CẤM. Đánh giá trung thực đòi hỏi test set được dùng **đúng một lần** ở bước cuối.

6. Baseline — Điểm tham chiếu đầu tiên

Trước khi xây model phức tạp, phải có **baseline** — chiến lược ngây thơ nhất:

- Classification: `DummyClassifier(strategy="most_frequent")` — luôn đoán lớp đa số;
- Regression: `DummyRegressor(strategy="mean")` — luôn đoán giá trị trung bình.

Vì sao baseline cần thiết? Câu hỏi đúng không phải “*Model của tôi có chính xác không?*” mà là:

Model của tôi có học được điều gì hữu ích vượt trội một chiến lược đơn giản không?

Ví dụ: hệ bệnh tim có 54.1% mẫu lớp 0 $\rightarrow$ baseline accuracy = 54.1%. Một model đạt 60% “nghe khá”, nhưng chỉ **hơn baseline 6 điểm** — bằng chứng học được khá yếu; ngược lại model đạt 85% là hơn hẳn 31 điểm. Không có baseline, mọi con số accuracy đều **không có ngữ cảnh** để diễn giải.

7. Bốn model truyền thống — Nguyên lý học của từng model

7.1 Logistic Regression (Classification)

$$z = w^T x + b, \quad \sigma(z) = \frac{1}{1 + e^{-z}}$$
$$x \rightarrow w^T x + b \rightarrow \sigma(\cdot) \rightarrow P(y = 1|x)$$

- **Representation nhận vào:** feature vector (cần chuẩn hóa để weight so sánh được);
- **Quan hệ học:** ranh giới quyết định **tuyến tính** trong không gian đặc trưng;
- **Tham số học:** $w \in \mathbb{R}^d, b \in \mathbb{R}$;
- **Tiêu chí học:** tối thiểu hóa cross-entropy loss (có thể + regularization);
- **Giả định:** quan hệ log-odds tuyến tính theo đặc trưng;
- **Mạnh:** diễn giải được (weight = đóng góp của feature), nhanh, baseline tốt;
- **Yếu:** bắt không được quan hệ phi tuyến/phương thức tương tác phức tạp.
- *Weight w_j dương lớn $\rightarrow$ tăng x_j làm tăng xác suất lớp 1; âm lớn $\rightarrow$ giảm.*

7.2 k-Nearest Neighbors (Classification/Regression)

$$d(x, x_i) = \sqrt{\sum_{j=1}^d (x_j - x_{ij})^2} \quad (\text{khoảng cách Euclid})$$

- **Representation nhận vào:** feature vector + **toàn bộ training set** (lazy learner);
- **Quan hệ học:** không học hàm tường minh — phân loại theo **lân cận** của điểm mới;
- “Tham số”: k (hyperparameter, không học từ dữ liệu);
- **Tiêu chí:** không có hàm loss tối thiểu hóa toàn cục;
- **Giả định:** các điểm gần nhau theo metric khoảng cách có nhãn tương tự;
- **Mạnh:** đơn giản, không giả định dạng hàm, bắt được ranh giới phi tuyến;
- **Yếu:** **feature scale chi phối khoảng cách** (Glucose ~100, Age ~40 $\rightarrow$ Glucose áp đảo); chậm lúc inference; degrade ở chiều cao.

Hệ quả quan trọng liên kết representation $\leftrightarrow$ model: Với KNN, *representation* và *preprocessing* kết nối với nhau — chuẩn hóa đặc trưng **thay đổi trực tiếp** hình học không gian và kết quả phân lớp. Đây là lý do Experiment 3 (representation) có ý nghĩa.

7.3 Support Vector Machine (Classification)

- **Representation nhận vào:** feature vector (chuẩn hóa gần như bắt buộc);
- **Quan hệ học:** ranh giới phân cách với **biên (margin) lớn nhất**;
- **Tham số:** vector hỗ trợ + hệ số siêu phẳng w, b ; kernel trick cho phi tuyến (RBF);
- **Tiêu chí học:** $\min \frac{1}{2} \|w\|^2 + C \sum \xi_i$ — tối đa margin, phạt vi phạm;
- **Giả định:** margin lớn $\rightarrow$ khái quát tốt;
- **Mạnh:** hiệu quả chiều cao, kernel linh hoạt;
- **Yếu:** nhạy với scale, chi phí $O(n^2) \rightarrow O(n^3)$, khó diễn giải.

*Good separation is not enough; **the margin matters.*** — nhiều ranh giới phân đúng training data, SVM chọn ranh giới **cách xa nhất** cả hai lớp để khái quát.

7.4 Decision Tree & Random Forest

Decision Tree:

- **Representation nhận vào:** feature vector (không cần scale — chia theo ngưỡng);
- **Quan hệ học:** chia đệ quy không gian đặc trưng theo tiêu chí tách;
- **Cấu trúc học:** cây các node điều kiện (feature, ngưỡng);
- **Tiêu chí học:** Gini impurity / entropy — mỗi lần chia tối đa độ tinh khiết;
- **Mạnh:** diễn giải cực tốt (vẽ cây ra đọc được), bất phi tuyến + tương tác;
- **Yếu:** **overfit mạnh** nếu không giới hạn độ sâu; bất ổn (nhỏ dữ liệu → cây khác hẳn).

Random Forest = Bagging + Random Feature Selection + Ensemble Prediction:

$$\hat{y} = \text{Vote}(T_1(x), \dots, T_B(x)) \quad (\text{classification})$$

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (\text{regression})$$

Mỗi cây: (1) nhìn **bootstrap sample** của dữ liệu; (2) mỗi split chỉ xét **subset ngẫu nhiên** các feature. Nhiều cây đa dạng → dự đoán **robust hơn** (giảm variance).

Với regression (hệ giá nhà), assignment dùng thêm:

7.5 Linear Regression (Regression)

$$\hat{y} = w^T x + b$$

- **Tiêu chí học:** tối thiểu hóa MSE $\sum_i (f_\theta(x_i) - y_i)^2$ (OLS có nghiệm đóng);
- **Giả định:** quan hệ tuyến tính, sai số iid Gaussian, không đa cộng tuyến mạnh;
- **Mạnh:** đơn giản, diễn giải được (hệ số = marginal effect);
- **Yếu:** bắt không được phi tuyến nếu không thêm biến đổi đặc trưng.

7.6 Support Vector Regression (Regression)

SVR tìm hàm $f(x)$ lệch khỏi y thực tế tối đa ϵ , đồng thời phẳng nhất có thể — phiên bản “margin” của regression: chỉ các điểm ngoài ϵ -tube mới đóng góp loss.

Điểm chung quan trọng (Slide 01, trang 44): các thuật toán nhận **cùng một representation** (feature vector) nhưng áp đặt **giả định và cơ chế học khác nhau** — đó là lý do so sánh chúng trong cùng protocol là một experiment có ý nghĩa khoa học.

8. Controlled Experiments — Từ “chạy model” đến thực nghiệm

Slide 01 (trang 52) phân biệt:

- **Experiment yếu:** “I trained KNN, SVM, and Logistic Regression. KNN was best.”
- **Experiment mạnh:** hỏi thêm “WHY?” — và thiết kế kiểm soát để trả lời.

8.1 Ba experiment bắt buộc

Experiment 1 — Model Comparison: ≥ 4 model, cùng protocol đánh giá, cùng train/test split → bảng Accuracy/Precision/Recall/F1 (hoặc MAE/MSE/RMSE/ R^2).

Experiment 2 — Hyperparameter Investigation: thay đổi **một** hyperparameter có ý nghĩa (k của KNN, độ sâu cây, số cây RF, C của SVM, regularization của LR...). *Phải nêu câu hỏi thực nghiệm TRƯỚC khi chạy.*

Experiment 3 — Representation/Feature Investigation: so sánh X_{all} vs $X_{selected}$, hoặc unscaled vs standardized. Trả lời: *representation thay đổi kết quả không, và vì sao?* — experiment này **trả lời trực tiếp triết lý Slide 01**.

8.2 Nguyên tắc đổi một biến

Một experiment có kiểm soát chỉ đổi **một yếu tố** và giữ nguyên phần còn lại. Đề bài cảnh cáo: “*Changing many parameters without an experimental question*” là không đủ chuẩn — mỗi lần đổi tham số phải **trả lời một câu hỏi**.

9. Evaluation — Accuracy là chưa đủ

9.1 Classification

Confusion matrix:

	Dự đoán +	Dự đoán -
Thực tế +	TP	FN
Thực tế -	FP	TN

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F_1 = \frac{2PR}{P + R}$$

Chọn metric nào tùy bài toán ứng dụng (yêu cầu bắt buộc của đề):

- **Hệ bệnh tim:** bỏ sót người bệnh (FN) nghiêm trọng hơn báo giả (FP) → **Recall là metric ưu tiên**, theo dõi Precision/F1 để đảm bảo không tăng báo giả quá cao. Accuracy đơn thuần gây hiểu lầm khi lớp mất cân bằng.
- Công thức F_1 là **trung bình điều hòa** của Precision và Recall — phạt nặng khi một trong hai thấp.

9.2 Regression

$$MAE = \frac{1}{N} \sum_i |\hat{y}_i - y_i|, \quad MSE = \frac{1}{N} \sum_i (\hat{y}_i - y_i)^2, \quad RMSE = \sqrt{MSE}$$

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

- **MAE:** sai số trung bình cùng đơn vị giá nhà (\$) — dễ diễn giải cho người dùng;
- **RMSE:** phạt lỗi lớn nặng hơn — quan trọng vì dự đoán lệch \$100k nghiêm trọng hơn nhiều so với \$10k;
- R^2 : phần phương sai mục tiêu model giải thích được (1.0 hoàn hảo, 0 = bằng baseline mean);
- **Hệ giá nhà:** R^2 là chỉ số tổng quát, RMSE nhấn sai số lớn, MAE để diễn giải cho người dùng cuối — báo cáo đủ cả bốn.

9.3 Model Selection là một quyết định

Câu hỏi không phải $\max(\text{Accuracy})$ mà là: model nào **khái quát tốt**? metric nào quan trọng với ứng dụng? model có **diễn giải được** không (y tế cần)? chi phí tính toán? có **deploy được đáng tin cậy** không?

10. Từ Model đến Intelligent Application

10.1 Model một mình chưa phải hệ thống

Pipeline ứng dụng phải hiện thực hóa đầy đủ:

Input → Representation → Preprocessing → Model → Prediction → Output

Ràng buộc nền tảng: Representation dùng cho input mới phải **GIỐNG HẾT** representation dùng lúc huấn luyện — cùng encoder, cùng scaler, cùng thứ tự cột. Đây chính là ý nghĩa câu Slide 01 (trang 56): “*New input must be represented and preprocessed in the same way as the training data.*”

10.2 Model Persistence + Deployment

```
# Lưu model sau huấn luyện
import joblib
joblib.dump(model, "model.joblib")

# Tải lại cho inference
model = joblib.load("model.joblib")
prediction = model.predict(X_new)
```

Kiến trúc deployment dạng **Prediction Service** (Slide 01, trang 57):

```
User/Client —request features—▶ REST API / Web App —▶ Saved ML Model (inference)
◀—prediction response—
```

Application does not need to know how the model learns. It needs a well-defined prediction interface.

Trong Assignment 01, em hiện thực hóa bằng **web app Streamlit** deploy lên **Hugging Face Spaces**: người dùng nhập chỉ số → app chuyển sang đúng representation huấn luyện → model trả dự đoán + xác suất → hiển thị kèm khuyến nghị. Đây là bước **Deploy** trong vòng phát triển Understand → Represent → Implement → Experiment → Evaluate → Deploy → Iterate.

10.3 Demonstration bắt buộc

Đề yêu cầu demo đường đi đầy đủ:

User/Environment → Input → Feature Representation → ML Model → Prediction

với **ít nhất 3 input case** — một case lành, một case mắc bệnh (với hệ tim); một nhà rẻ, một nhà trung bình, một nhà đắt (với hệ giá nhà) — chứng minh cùng một pipeline xử lý mọi case.

11. Reflection — Điều gì làm hệ thống này “intelligent”?

11.1 Bảy câu hỏi reflection bắt buộc (mục 18 đề)

1. **Hệ thống nhận thông tin gì?** Chỉ số measument của bệnh nhân / đặc điểm nhà;
2. **Representation nội bộ là gì?** Feature vector $x \in \mathbb{R}^d$ sau encode + scale;
3. **Model học gì từ ví dụ?** Quan hệ ánh xạ feature → target $f_\theta : x \mapsto \hat{y}$;
4. **Dự đoán/quyết định gì?** Xác suất bệnh tim (ngưỡng 0.5) / mức giá ước tính (\$);
5. **Vì sao xử lý được input chưa thấy?** **Khái quát hóa**: học quan hệ có cấu trúc (pattern) chứ không ghi nhớ từng mẫu — miễn input mới cùng phân phối với training data;
6. **Phần nào gọi là “intelligent” hợp lý?** Khả năng **học từ ví dụ + khái quát + dự đoán đúng** — năng lực không ai lập trình luật tường minh;
7. **Hạn chế gì ngăn trở việc thông minh hơn?** (mục 11.2).

11.2 Hạn chế của representation feature vector (mục 19 đề)

- **Lưu giữ**: các thuộc tính đo đếm/chốt được chọn — tín hiệu dự báo chính;
- **Mất**: quan hệ giữa các thực thể, dữ liệu ảnh/Y tế gốc (ECG thô, ảnh chụp), chuỗi thời gian, ngữ cảnh lâm sàng, tri thức y khoa chuyên gia;
- **Image?** Có thể — ảnh siêu âm tim / ảnh chụp nhà → tensor → CNN (A4 của môn học);
- **Sequence?** Có thể — chuỗi ECG theo thời gian, lịch sử giao dịch nhà;
- **Graph?** Có thể — đồ thị bệnh-triệu chứng, mạng lưới vị trí nhà-trường học-trung tâm;
- **Learned embeddings?** Có thể — embedding mã hóa bệnh nhân/nhà tương tự nhau gần nhau;

- **Đổi representation thì đổi gì?** Đổi thông tin có sẵn → đổi họ hàm học được → đổi trần khả năng dự đoán (nhưng thường đổi cả chi phí dữ liệu + mất diễn giải).

trained model $\neq$ complete intelligent system

Hệ thống hoàn chỉnh cần thêm: input handling, representation, preprocessing, prediction, output, và **tích hợp vào application**.

12. Vị trí của Assignment 01 trong lộ trình môn học

Structured Data → Feature Engineering → Traditional ML → Prediction
input representation learning decision

Trong dòng chảy lịch sử:

Symbolic AI → Expert Systems → **Statistical ML** → Deep Learning → Foundation/Gen AI → Interactive/Agentic

Assignment 01 chiếm giai đoạn **Statistical ML** — giai đoạn mà con người thiết kế representation (feature vector) và máy học quan hệ dự đoán.

Lộ trình 5 assignment:

Giai đoạn	Representation chính	Năng lực chính
A1	Feature vectors	Traditional ML + deployment ← vị trí hiện tại
A2	Data / improved representations	Preprocessing + evaluation
A3	Learned representations	Neural networks + deep learning
A4	Tensors + graphs	CNN + relational knowledge
A5	Embeddings + context	RAG + conversational systems
Project	Integrated representations	Complete intelligent system

Tiến trình dài hạn: Data → Representation → Learning → Knowledge → Retrieval → Generation → Interaction → **Intelligent System**.

13. Kết luận lý thuyết

Assignment 01 là **bước hiện thực hóa đầu tiên** của khung khái niệm Slide 01:

Understand → Represent → Implement → Experiment → Evaluate → Apply

Ba luận điểm trung tâm được Parts 2 (thực hành) chứng minh:

1. **Representation là xương sống**: model không nhận thể giới thực mà nhận representation — representation quyết định thông tin sẵn có cho học. Hai hệ thống thực nghiệm (bệnh tim, giá nhà) sẽ cho thấy đổi representation (scale, chọn feature, log-transform) **thay đổi kết quả học**.
2. **Learning = học từ ví dụ + khái quát + dự đoán**: baseline cho khung tham chiếu, ≥ 4 model cùng representation so sánh theo protocol thống nhất, 3 controlled experiment trả lời câu hỏi đặt trước.
3. **Model $\neq$ hệ thống**: chỉ khi model được bọc trong pipeline Input → Representation → Preprocessing → Model → Prediction → Output và **deploy thành application** (web app) thì mới có một *intelligent system nhỏ* hoàn chỉnh — intelligent system **đầu tiên** em phát triển trong môn học này.

Tài liệu tham khảo

1. Tran, D. Q., *Intelligent System Development — Lecture 01: From Intelligence to Intelligent Systems*, PTIT.

2. Tran, D. Q., *Intelligent System Development — Assignment 01: From Data Representation to a First Intelligent System*, PTIT.
3. Lee, W.-M., *Python® Machine Learning*, First Edition, Wiley, 2019 — Chương 12: Deploying Machine Learning Models.
4. Scikit-learn documentation: machine learning algorithms and model evaluation.
5. Russell, S. and Norvig, P., *Artificial Intelligence: A Modern Approach*.
6. Goodfellow, I., Bengio, Y., and Courville, A., *Deep Learning*.
7. Vaswani, A. et al., "Attention Is All You Need," 2017.