

Phần 2 — Báo cáo kỹ thuật

PHẦN 2 — BÁO CÁO KỸ THUẬT: HAI HỆ THỐNG THÔNG MINH

Môn học: Intelligent System Development — Assignment 01 *From Data Representation to a First Intelligent System*

Hai hệ thống: 🍷 **Hệ Chẩn đoán bệnh tim** (classification) và 🏠 **Hệ Dự đoán giá nhà** (regression) — cùng một methodology *Understand → Represent → Implement → Experiment → Apply*.

1. Introduction

Assignment 01 yêu cầu phát triển **một intelligent system nhỏ** — không chỉ “train classifier” — theo khung Slide 01: Intelligence → Intelligent System → Representation → Learning → Decision → Action.

Báo cáo này trình bày **hai hệ thống** trên hai bài toán có bản chất khác nhau về bản chất học:

	🍷 Hệ Chẩn đoán bệnh tim	🏠 Hệ Dự đoán giá nhà
Loại bài toán	Binary classification	Regression
Target	Có/không bệnh tim (0/1)	Giá bán USD (liên tục)
Metric chính	Recall, F1, Accuracy, Precision	MAE, RMSE, R^2
Model cuối	Random Forest (B=100)	Random Forest Regressor (B=100, log-target)
Ứng dụng	Sàng lọc tim mạch cho nhân viên y tế	Ước giá nhà cho người mua/bán

Hai hệ thống cùng dùng **một quy trình 22 mục** (Required Notebook Structure — mục 21 đề), cùng kỷ luật thực nghiệm, nhưng khác nhau ở mọi quyết định kỹ thuật do bản chất classification/regression chi phối — đó chính là bài học so sánh mà báo cáo này làm rõ.

Lưu ý về lựa chọn dataset: Slide 67 quy định “*Do not simply reproduce Lee’s diabetes example*” — diabetes chỉ là scaffold. Hai dataset được chọn là dataset thật, khác hoàn toàn ví dụ lớp: UCI Heart Disease (Cleveland) và Kaggle Ames Housing.

2. Intelligent System Definition

2.1 Hệ Chẩn đoán bệnh tim

System statement:

Hệ thống hỗ trợ sàng lọc bệnh tim nhận 13 chỉ số tim mạch đo lường được của bệnh nhân, biểu diễn thành feature vector $x \in \mathbb{R}^{13}$ (sau encode: $\mathbb{R}^{18}$), dùng model học từ 303 bệnh nhân để dự đoán xác suất hẹp động mạch vành, hỗ trợ nhân viên y tế ưu tiên bệnh nhân cần khám chuyên sâu.

2.2 Hệ Dự đoán giá nhà

System statement:

Hệ thống ước tính giá nhà nhận các thuộc tính bất động sản (diện tích, chất lượng, vị trí, năm xây...), biểu diễn thành feature vector (sau encode: $\mathbb{R}^{271}$) + log-transform target, dùng model học từ 1460 giao dịch Ames, Iowa để dự đoán giá bán USD, hỗ trợ người mua/bán/đại lý định giá tham khảo.

2.3 Kiến trúc chung của hai hệ thống

ENVIRONMENT → INPUT → REPRESENTATION → PREPROCESSING → MODEL → PREDICTION → OUTPUT → USER

(web app) (one-hot + scale) (RF) (class/giá)

feedback: dữ liệu mới ↩

Cả hai hiện thực đầy đủ chuỗi Slide 01: external information (dataset) → internal representation (feature vector) → learning (traditional ML) → decision (prediction) → action (application deploy).

3. Problem Definition

Thành phần	 Bệnh tim	 Giá nhà
Input x	13 chỉ số tim mạch	74 thuộc tính nhà
Target y	$\{0, 1\}$ — có/không bệnh	$\mathbb{R}$ — giá USD
Bài toán	Binary classification	Regression
Định nghĩa 1 câu	Given the 13-dim feature vector, predict heart disease class	Given house feature vector, predict sale price in USD
Learning objective	$\theta^* = \arg \min_{\theta} \frac{1}{N} \sum \ell(f_{\theta}(x_i), y_i)$	cùng công thức, ℓ = squared loss trên log-giá

4. Dataset

4.1 UCI Heart Disease (Cleveland)

Thuộc tính	Giá trị
Nguồn	https://archive.ics.uci.edu/dataset/45/heart+disease
Quan sát	303 bệnh nhân (Cleveland Clinic)
Feature	13 (6 numerical + 7 categorical)
Target	num 0–4 → nhị phân (num>0 = có bệnh)
Cân bằng lớp	164 khỏe / 139 bệnh (54/46) — cân bằng tốt
Citation	Janosi, Steinbrunn, Pfisterer, Detrano (1988)

Tiền xử lý: median imputation cho `ca` (4 thiếu), `tha1` (2 thiếu) — tỷ lệ ~2% quá nhỏ để bỏ hàng.

4.2 Kaggle Ames Housing

Thuộc tính	Giá trị
Nguồn	https://www.kaggle.com/c/house-prices-advanced-regression-techniques

Thuộc tính	Giá trị
Quan sát	1460 giao dịch (Ames, Iowa 2006–2010)
Feature	74 sau xử lý (36 numerical + 38 categorical)
Target	SalePrice (\$34,900 – \$755,000, lệch phải skew 1.88)
Citation	De Cock (2011), J. Statistics Education 19(3)

Tiền xử lý tinh tế: **NA của Ames mang nghĩa “không có tiện ích”** (không phải missing!) — Garage*, Bsmt*, FireplaceQu NA → “None”; bỏ 5 cột thiếu >50%; LotFrontage → median theo Neighborhood.

5. Data Representation

5.1 Nguyên lý chung

Raw feature $\neq$ Encoded feature $\neq$ Model input

5.2 So sánh representation hai hệ thống

	📈 Bệnh tim	🏠 Giá nhà
Raw	13 cột (7 categorical mã số)	74 cột (38 chuỗi văn bản)
Encoded	one-hot 7 categorical → 18 chiều	one-hot 38 categorical → 271 chiều
Model input	standardized trong Pipeline	standardized trong Pipeline
Representation của target	nhãn 0/1 (nguyên bản)	log(1+y) — chính là thay đổi representation!
Lý do chọn	one-hot tránh giả thứ tự sai (cp 1–4 vô thứ tự)	one-hot giữ 25 khu Neighborhood không áp thứ tự

Điểm nhấn: ở hệ giá nhà, việc log-transform target *chính là một quyết định representation* — không chỉ input mới là representation. Experiment 3 chứng minh quyết định này cải thiện mọi model.

6. Traditional ML Methods

6.1 Bốn model mỗi hệ thống (đúng mục 13 đề)

Hệ tim (classification): Logistic Regression, k-NN (k=11), SVM (RBF, C=1), Random Forest (B=100).

Hệ nhà (regression): Linear Regression, Decision Tree Regressor (depth 8), Random Forest Regressor (B=100, log-target), SVR (RBF).

6.2 Model understanding — bảng tổng hợp 7 câu hỏi

Câu hỏi	LR	KNN	SVM/DT	RF
Representation nhận?	vector chuẩn hóa (cần)	vector chuẩn hóa (bắt buộc — khoảng cách)	SVM cần scale / DT không cần	không cần scale
Quan hệ học?	ranh giới tuyến tính	lân cận theo khoảng cách	margin tối đa / chia đệ quy	ensemble trung bình/vote
Tham số?	w, b	không có (lazy)	siêu phẳng / cấu trúc cây	100 cây
Tiêu chí?	cross-entropy (log)	không loss toàn cục	margin + hinge / Gini	Gini từng cây + variance reduction
Giả định?	log-odds tuyến tính	điểm gần nhau cùng lớp	margin lớn → khái quát	cây đa dạng → lỗi triệt tiêu
Mạnh?	diễn giải, nhanh	đơn giản, phi tuyến cục bộ	hiệu quả chiều cao / diễn giải cây	hiệu năng top, robust
Yếu?	chỉ tuyến tính	curse of dim, chậm inference	nhạy C, γ , khó diễn giải / overfit	black box hơn

(Chi tiết từng model + công thức: notebook mục 10–13 mỗi hệ.)

7. Experimental Design

Cả hai hệ thống thực hiện **đúng 3 controlled experiments**, mỗi experiment đặt **câu hỏi trước khi chạy** (mục 15 đề):

Experiment	Câu hỏi	Hệ tim	Hệ nhà
1. Model comparison	Model nào tốt nhất dưới cùng protocol?	4 model × 5-fold CV (F1)	4 model × 10-fold CV (R ²)
2. Hyperparameter	Đổi 1 tham số → thay đổi gì?	RF: $B \in \{1..400\}$; KNN: $k \in \{1..31\}$	DT: depth $\in \{2..None\}$; RF: $B \in \{5..400\}$
3. Representation	Đổi representation → thay đổi gì? (a) raw vs standardized (b) X_{all} vs X_{top6}	(a) raw vs log-target (b) X_{all} vs X_{top8}	

Kỷ luật: mọi quyết định phát triển dùng cross-validation trên train; test set chỉ dùng **một lần** ở Evaluation (tránh danh mục cấm của đề).

8. Results

8.1 Hệ Chẩn đoán bệnh tim — test set (n=61)

Model	Accuracy	Precision	Recall	F1
Random Forest (100)	0.885	0.839	0.929	0.881
KNN (k=11)	0.885	0.862	0.893	0.877
Logistic Regression	0.836	0.800	0.857	0.828
SVM (RBF)	0.836	0.800	0.857	0.828
Baseline (majority)	0.541	0.000	0.000	0.000

Phân tích: cả 4 model vượt baseline áp đảo (F1: 0 → 0.83–0.88) — học được tín hiệu thật. RF có **Recall 0.929** cao nhất — chỉ bỏ sót 2/28 người bệnh (FN nhỏ nhất), đúng ưu tiên y tế. AUC của các model 0.90–0.93 (mức excellent cho sàng lọc).

8.2 Hệ Dự đoán giá nhà — test set (n=292)

Model	MAE	RMSE	R ²
Random Forest (log-target)	\$17,277	\$29,297	0.888
Linear Regression	~\$23k	~\$35k	~0.84
Decision Tree	~\$22k	~\$34k	~0.85
SVR (RBF, default)	~\$28k	~\$41k	~0.77

Model	MAE	RMSE	R ²
Baseline (mean)	\$59,931	\$88,271	-0.016

Phân tích: RF MAE $\approx$ \$17k $\approx$ 10.6% median giá — vượt baseline 3.5×. Residual phân bố quanh 0 không theo pattern → model đã vắt hết phần tuyến tính. LR bị “kéo về trung bình” ở nhà đắt ($>$ \$400k dự đoán thấp hơn thật) — đúng hạn chế lý thuyết tuyến tính ở đuôi phân phối.

8.3 Kết quả 3 experiments

Hệ tim: - **Exp 1:** Xếp hạng RF $\approx$ SVM $>$ LR $>$ KNN ổn định qua 5 fold; - **Exp 2:** RF F1 tăng từ 0.70 (1 cây) → $\sim$ 0.78 (50+ cây) rồi **bão hòa** — thêm cây chỉ giảm variance; KNN tối ưu k=13; - **Exp 3a:** Standardization: **SVM +0.313 F1, KNN +0.208** (thay đổi rất lớn!), LR -0.007, RF -0.007 (miễn nhiễm); - **Exp 3b:** Top-6 feature giữ $\sim$ 95% hiệu năng.

Hệ nhà: - **Exp 1:** RF $>$ DT $>$ LR $>$ SVR(default) qua 10 fold; - **Exp 2:** DT depth 2 (R² 0.58 — underfit) → 8–12 ($\sim$ 0.75 tối ưu) → đi ngang (overfit bắt đầu); RF bão hòa B $\approx$ 100; - **Exp 3a: log-target cải thiện mọi model** (LR, RF, SVR đều Δ dương); - **Exp 3b:** Top-8 feature giữ gần nguyên hiệu năng (Δ chỉ -0.03 với RF).

9. Model Comparison — vì sao chọn Random Forest cho cả hai hệ?

Model selection là **quyết định đa tiêu chí** (Slide 01 trang 54), không phải max(accuracy):

Tiêu chí	Đánh giá cho cả 2 hệ
Hiệu năng	RF cao nhất + ổn định nhất (IQR hẹp nhất qua folds)
Metric ưu tiên ứng dụng	Tim: Recall cao nhất (0.929); Nhà: MAE thấp nhất
Diễn giải	Có feature importance (OverallQual trội ở nhà; ca, tha1 ở tim)
Chi phí inference	100 cây $\times$ vài ms — vô hình với web app
Robust	Tim: không cần scale → pipeline app ít rủi ro mismatch; Nhà: bất biến với outlier
Ổn định tham số	Exp 2: bão hòa từ B $\approx$ 100 → không nhảy

10. Representation Analysis — bằng kênh triết lý Slide 01

Ba nguồn bằng chứng độc lập hội tụ trong cả hai hệ:

1. **EDA** (histogram theo lớp, scatter, correlation): nhận diện feature mạnh;
2. **LR weights/coefficients**: xác nhận hướng + sức ảnh hưởng;
3. **RF feature importance**: xác nhận ranking.

	📈 Bệnh tim	🏠 Giá nhà
Feature trội	ca (số mạch hẹp), thal, cp, oldpeak, thalach	OverallQual (0.55+), GrLivArea, TotalBsmtSF, GarageCars
Feature yếu	chol, trestbps	các tiện nghi hiếm
Redundancy	không có cặp $\rho > 0.6$	Garage ↔ GarageArea 0.88, Bsmt ↔ 1stFlr 0.81

Kết luận trung tâm (trả lời trực tiếp Slide 01): Representation không phải lựa chọn trung tính:

- Cùng KNN, đổi raw → standardized: **+0.208 F1**;
- Cùng SVM: **+0.313 F1**;
- Cùng RF hệ nhà, đổi target raw → log: R^2 cải thiện rõ;
- Nhưng cùng RF hệ tim: **~0 thay đổi** khi scale.

→ Ảnh hưởng của representation **phụ thuộc cơ chế học của model** (khoảng cách/margin nhảy, split theo ngưỡng miễn dịch) — mỗi cặp (representation, model) là một quyết định thiết kế phải thử nghiệm, không suy ra được trên giấy.

11. Intelligent Application

11.1 Kiến trúc ứng dụng (cả hai hệ)

Người dùng (web) → Streamlit UI → predict() → one-hot reindex đúng cột huấn luyện → RF model → kết quả + khuyến nghị

Nguyên lý bắt buộc: cùng representation dùng lúc huấn luyện được tái dựng chính xác cho input mới — app lưu `enc_columns` + danh sách categorical trong artifacts joblib, hàm predict `reindex(columns=enc_columns, fill_value=0)` đảm bảo vector 18/271 chiều đúng hệ.

11.2 Hệ tim (apps/heart_app/)

- Form 13 chỉ số (slider/selectbox tiếng Việt kèm giải thích y khoa);
- Output: xác suất + ngưỡng 0.5 + kết luận + **cảnh báo vùng mơ hồ 0.35–0.65**;
- 3 preset case demo 1-click (nguy cơ thấp/cao/biên);
- Disclaimer y tế.

11.3 Hệ nhà (apps/house_app/)

- 3 tab input (chất lượng, diện tích, vị trí) — người dùng nhập 8 feature quyết định, feature phụ dùng median/mode train (thiết kế từ Exp 3b);
- Output: giá ước tính + **dải tham chiếu $\pm$ MAE/RMSE** + so median Ames;
- Cảnh báo độ tin cậy thấp ở phân khúc cao cấp;
- 3 preset phân khúc.

11.4 Deploy

Cả hai app **Streamlit deploy lên Hugging Face Spaces** (miễn phí, không cần thẻ tín dụng) — hướng dẫn từng bước tiếng Việt trong `apps/HUONG_DAN_DEPLOY.md`. Đã test local end-to-end bằng browser automation: cả 2 app chạy đúng (case nguy cơ cao → “CÓ BỆNH TIM” 96%; nhà cao cấp NridgHt → \$302,408).

12. Limitations

Hạng mục	📄 Bệnh tim	🏠 Giá nhà
Dữ liệu	303 mẫu — nhỏ; 1 trung tâm y tế (Cleveland) — hạn chế khái quát đa dân số	1 thị trường nhỏ, 2006–2010 (bao gồm khủng hoảng BĐS) — stale theo thời gian
Representation	Mất ECG chuỗi thời gian, ảnh siêu âm, hồ sơ văn bản, quan hệ bệnh–thuốc	Mất ảnh hiện trạng, mô tả listing, động lực bán, xu hướng vĩ mô
Model	RF không cho khoảng tin cậy chuẩn; không extrapolate ngoài phạm vi feature đã thấy	Không dự đoán ngoài max giá train (\$755k); cần retrain khi thị trường đổi
Ứng dụng	Sàng lọc tham khảo — KHÔNG thay thế bác sĩ; 13 chỉ số nhập tay	8 feature chính; feature phụ cố định median — không phản ánh nhà bất thường
Đánh giá	1 split 80/20 (+CV) — với N=303 khoảng tin cậy còn rộng	Tương tự; chưa kiểm tra drift theo YrSold

13. Reflection

13.1 Điều gì làm hệ thống “intelligent”? (mục 18 đề — 7 câu)

Trả lời đầy đủ trong notebook mục 21 của mỗi hệ. Cốt lõi:

- **Phần intelligent hợp lý:** học từ ví dụ + khái quát + dự đoán đúng trên input chưa thấy — năng lực không ai lập trình luật tường minh. Bằng chứng: Recall 0.93 trên 61 bệnh nhân / R^2 0.89 trên 292 nhà model chưa từng thấy;
- **Vì sao xử lý được input mới:** model học **cấu trúc quan hệ** (pattern) chứ không ghi nhớ mẫu — với input cùng phân phối, pattern hội tụ cho dự đoán đúng;
- **Trained model $\neq$ complete intelligent system:** model chỉ 1 thành phần. Hệ thống hoàn chỉnh = input handling + representation + preprocessing + prediction + output + **application deploy** + (tương lai) feedback loop.

13.2 Representation reflection (mục 19 đề — 8 câu)

Câu hỏi	 Bệnh tim	 Giá nhà
Vì sao phù hợp?	13 chỉ số là tín hiệu lâm sàng chuẩn, đủ thừa để học với 303 mẫu	Thuộc tính hồ sơ là thứ người định giá thật sự xem
Giữ gì?	chỉ số đo đếm chính xác	quan hệ giá–thuộc tính tính toán được
Mất gì?	ECG thô, ảnh, ngữ cảnh lâm sàng	ảnh, mô tả văn bản, động lực bán, chuỗi thời gian
Image?	ảnh siêu âm/MRI → CNN (A4)	ảnh mặt tiền/nội thất → CNN (kiểu Zestimate)
Sequence?	chuỗi ECG → RNN/Transformer (A3)	chuỗi giá giao dịch khu vực → time-series
Graph?	đồ thị bệnh–triệu chứng–thuốc → GNN/KG (A4)	đồ thị nhà–đường–trường học → GNN không gian
Embedding?	embedding bệnh nhân từ hồ sơ (A5)	embedding mô tả listing (A5)
Đổi thì sao?	nhiều thông tin hơn → trần cao hơn, nhưng mất diễn giải + cần deep learning + dữ liệu lớn	tương tự

Thông điệp kết nối course roadmap: *Different information representations* $\Rightarrow$ *different learning methods* — chính là lý do A3 (deep learning), A4 (graph), A5 (embedding/RAG) tồn tại sau A1.

14. Conclusion

Hiện thực hóa khung Understand $\rightarrow$ Represent $\rightarrow$ Implement $\rightarrow$ Experiment $\rightarrow$ Apply cho hai hệ:

	 Bệnh tim	 Giá nhà
Understand	Sàng lọc nhị phân từ 13 chỉ số	Ước giá regression từ 74 thuộc tính
Represent	one-hot 18 chiều	one-hot 271 chiều + log-target
Implement	baseline + 4 classifier	baseline + 4 regressor
Experiment	3 experiments — RF $\approx$ SVM>LR>KNN; B bảo hòa 50; scale +0.21/+0.31 cho KNN/SVM	3 experiments — RF>DT>LR>SVR; depth 8–12; log-target tốt hơn mọi model
Apply	RF (F1 0.88, Recall 0.93) $\rightarrow$ Streamlit app	RF (R^2 0.89, MAE \$17k) $\rightarrow$ Streamlit app

Ba thông điệp lớn của Assignment 01 (khớp Slide 01):

1. **Representation là xương sống** — model không nhận thể giới thực mà nhận representation của thông tin được chọn; đổi representation (scale, log-target, chọn feature) thay đổi kết quả học theo cách phụ thuộc cơ chế model;
 2. **Baseline + controlled experiments + metric đúng** là điều kiện để nói “model học được điều gì hữu ích” — không phải con số accuracy trớ trêu;
 3. **Model $\neq$ hệ thống** — chỉ khi bọc model trong pipeline Input $\rightarrow$ Representation $\rightarrow$ Preprocessing $\rightarrow$ Model $\rightarrow$ Prediction $\rightarrow$ Output và **deploy thành web app** thì mới có intelligent system nhỏ hoàn chỉnh. Đây là intelligent system đầu tiên của lộ trình 5 assignment; các assignment sau sẽ thay representation (tensor, graph, embedding) và mở rộng năng lực học.
-

Phụ lục: Đối chiếu 14 Explicit Requirements (R1–R14)

#	Yêu cầu	Bằng chứng
R1	Real dataset	UCI Heart Disease + Kaggle Ames (nguồn + citation trong notebook mục 3)
R2	System definition	System statement + diagram (notebook mục 1–2)
R3	Representation	3 tầng raw/encoded/input + bảng feature (mục 5)
R4	Feature analysis	EDA 4 biểu đồ + giải thích từng cái (mục 6 + 4)
R5	Problem formulation	Câu formal 1 câu + công thức D, f_{θ}, θ^* (mục 1)
R6	Baseline	DummyClassifier/DummyRegressor + phân tích “vì sao cần” (mục 9)
R7	≥ 4 models	LR, KNN, SVM, RF (tim) / LR, DT, RF, SVR (nhà) — hiểu model 7 câu mỗi cái
R8	≥ 3 experiments	Model comparison + hyperparameter + representation — mỗi cái có câu hỏi trước
R9	Metrics + giải thích	Tim: 4 metric + CM + ROC; Nhà: MAE/MSE/RMSE/ R^2 + residual — kèm vì sao chọn
R10	Scientific analysis	Mỗi kết quả có “vì sao” (scale/margin/variance...)
R11	Application	2 app Streamlit + hàm predict đúng representation
R12	System demonstration	3 case mỗi hệ qua pipeline đầy đủ + screenshot app
R13	Reflection	7+8 câu trả lời đầy đủ (mục 21 notebook)
R14	Reproducibility	RANDOM_STATE=42, data local, requirements, notebook chạy end-to-end

Phụ lục: Cấu trúc deliverables nộp kèm

```
assignment01/
├─ docs/
│   ├─ phan1_ly_thuyet.md/.pdf      ← Phần 1: lý thuyết (11 trang)
│   └─ phan2_bao_cao_ky_thuat.md    ← file này
│       └─ phan2_bao_cao_ky_thuat.pdf
├─ notebooks/
│   ├─ 01_heart_disease_system.ipynb (73 cells, output đầy đủ)
│   └─ 02_house_price_system.ipynb  (70 cells, output đầy đủ)
├─ data/
│   ├─ heart_clean.csv              (303 × 14 – nguồn: UCI)
│   ├─ ames_clean.csv              (1460 × 75 – nguồn: Kaggle)
│   └─ ames_train.csv              (gốc Kaggle tải về)
├─ artifacts/
│   ├─ heart_model.joblib           (RF classifier + metadata representation)
│   └─ ames_model.joblib           (RF regressor + metadata)
├─ apps/
│   ├─ heart_app/ (app.py + model + requirements)
│   ├─ house_app/ (app.py + model + requirements)
│   └─ HUONG_DAN_DEPLOY.md         ← hướng dẫn deploy HF Spaces tiếng Việt
├─ figures/                        (26 biểu đồ + 2 screenshot app)
└─ README.md                       ← hướng dẫn chạy toàn bộ
```